RELATÓRIO EXECUTIVO

Pipeline de Dados da Alfabetização

Análise de Indicadores de Alfabetização — INEP

Tech Challenge • Fase 2

Suelen de Paula Prado Ramos – RM 376528

02 de novembro de 2026

1. Resumo executivo

O projeto implementa uma pipeline de dados para organizar informações públicas de alfabetização do INEP e disponibilizá-las para análises educacionais. A solução utiliza BigQuery como origem, Databricks para ingestão, tratamento, qualidade e organização analítica, e AWS Step Functions para coordenar a execução dos sete Jobs.

A arquitetura adota três camadas Bronze, Silver e Gold e inclui monitoramento, alertas, uma simulação de processamento contínuo de eventos e uma projeção de custos com quantidades medidas, de cerca de US$ 38 por mês. Os dashboards apresentam visões nacional, municipal e por rede de ensino.

Na execução registrada em 26/10/2026, o fluxo completo levou 21 minutos e 02 segundos, com 41 etapas registradas e nenhuma falha. As evidências de qualidade incluem concordância de 99,5% entre a taxa recalculada e a taxa oficial em 12.351 de 12.408 recortes, além de relacionamentos Silver acima do limite mínimo de 95% e quatro relacionamentos fato-dimensão Gold com 100% de correspondência.

Indicadores nacionais exibidos no dashboard

Indicador	Valor exibido
Taxa média de alfabetização	61,5
Municípios avaliados	5,5 mil

Os valores devem ser interpretados conforme os filtros e a definição utilizados no dashboard. A taxa média é reproduzida na escala exibida pelo painel.

2. Problema de negócio e objetivo

Indicadores educacionais provenientes de diferentes tabelas precisam ser integrados, padronizados e validados antes de serem utilizados em análises. Diferenças de estrutura, chaves ausentes, duplicidades e relacionamentos incompletos podem prejudicar comparações entre municípios, estados, redes de ensino e metas.

O objetivo é criar uma base organizada e monitorada que facilite o acompanhamento dos resultados de alfabetização e apoie análises para gestores e equipes educacionais.

3. Arquitetura da solução

Componente	Responsabilidade	Evidência validada
Bronze	Receber e preservar dados de origem, com identificação de lote e data de ingestão.	Job de ingestão executado; exemplo de uf_raw com 145 registros.
Silver	Limpar, padronizar, validar chaves e verificar relacionamentos.	Correspondência de 97,78%, 99,95% e 100%.
Gold	Organizar fatos e dimensões para consultas e análises.	Tabelas fato registradas com sucesso; quatro relacionamentos testados a 100%.
AWS Step Functions	Orquestrar os sete Jobs Databricks em sequência.	Captura mostra os sete Jobs concluídos com sucesso.
Monitoramento	Registrar execuções, resultados de qualidade e alertas.	Cinco alertas SQL com avaliação horária.

A origem foi acessada diretamente pelo BigQuery, por meio da Base dos Dados, evitando download manual e permitindo que atualizações publicadas na fonte sejam capturadas em uma nova execução. O processamento ocorre no Databricks sobre AWS, enquanto a origem permanece no Google Cloud. Essa decisão facilita o acesso à fonte já disponibilizada, mas introduz uma arquitetura multi-cloud, com governança, permissões e custos de transferência entre provedores a acompanhar.

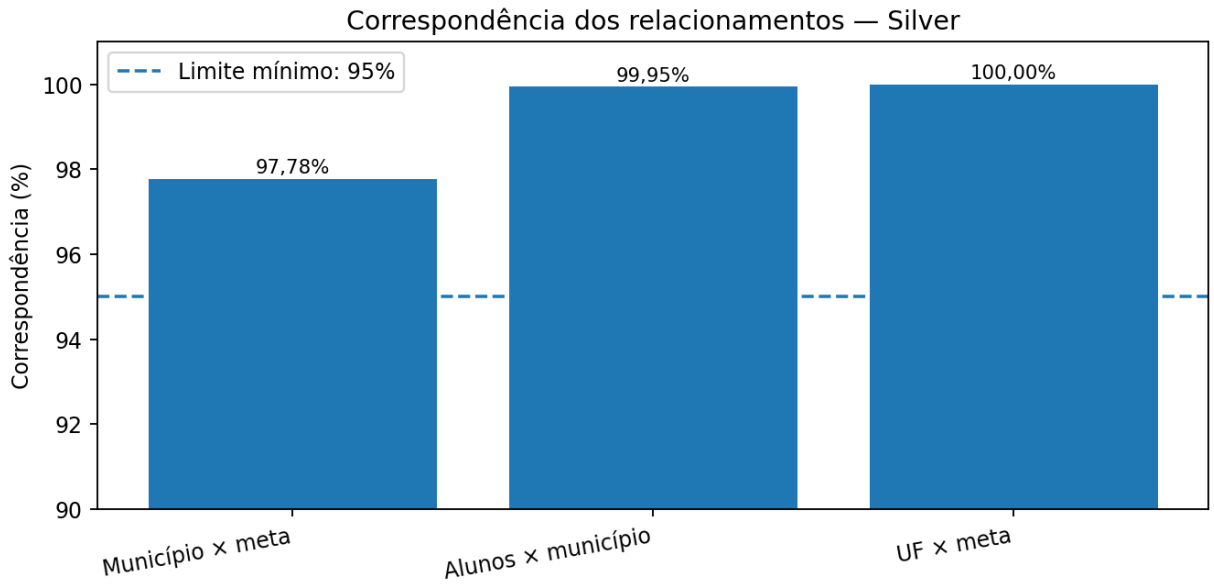
Fluxo: ingestão Bronze → qualidade Bronze → tratamento Silver → qualidade Silver → dimensões Gold → fatos Gold → qualidade Gold. A execução apresentada na captura da Step Functions terminou com sucesso nas sete etapas.

4. Qualidade e confiabilidade dos dados

Na Bronze, as verificações apresentadas incluem lote vazio, metadados nulos, chave nula e chave duplicada. Na execução capturada, as regras bloqueantes de lote vazio, metadados nulos e chave nula passaram. A regra de chave duplicada é informativa e também apareceu como aprovada nessa execução.

4.1 Correspondência na camada Silver

O limite mínimo configurado para os relacionamentos avaliados é de 95%. Os três resultados apresentados superaram esse limite:



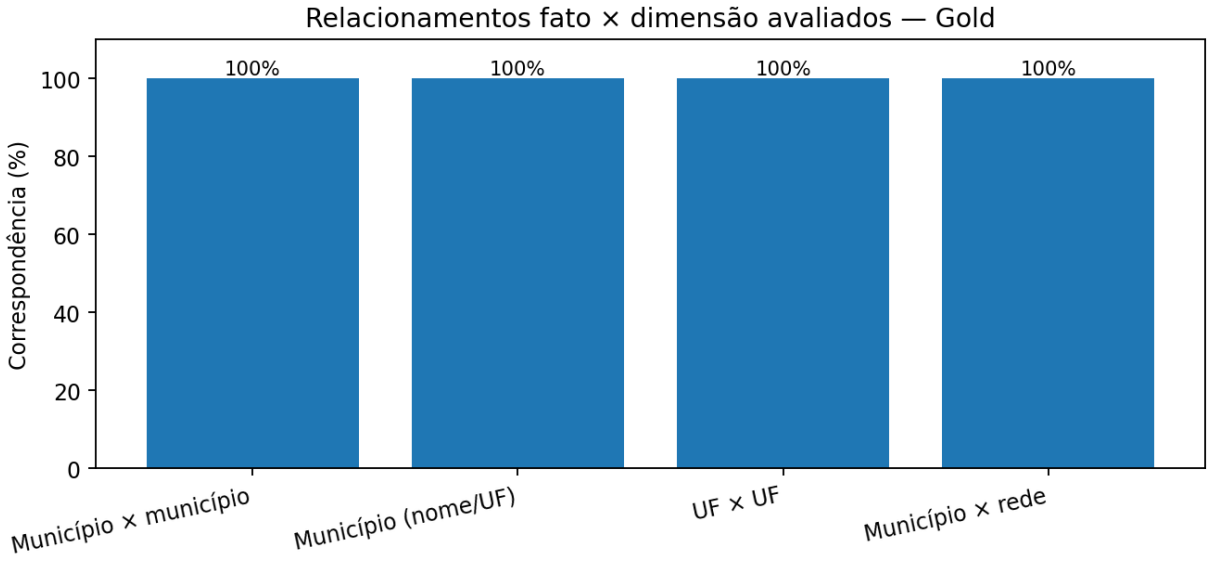
Fonte: saída do Job de Qualidade Silver (Job 04 — Qualidade Silver). As inconsistências informativas permanecem registradas.

Verificação informativa	Ocorrências
Município sem meta municipal correspondente	242
Registro de aluno sem município correspondente	3.209

Essas ocorrências foram registradas como informativas e não bloquearam a execução. A ausência de correspondência não deve ser interpretada automaticamente como erro de origem; é necessário considerar o período e o escopo das tabelas comparadas.

4.2 Correspondência na camada Gold

Quatro relacionamentos entre tabelas fato e dimensões foram avaliados e apresentaram 100% de correspondência na execução capturada.



Fonte: saída do Job 07 — Qualidade Gold. O percentual se refere aos quatro relacionamentos exibidos, não a todas as relações possíveis do modelo.

Verificação informativa	Ocorrências
Registros sem meta municipal	216
Registros sem meta estadual	1
Registros sem meta nacional	1
Alunos presentes sem peso amostral	1.185

O Job Gold terminou com zero bloqueios e gate liberado. As verificações informativas de metas ausentes e de alunos sem peso amostral permaneceram registradas.

4.3 Teste controlado de falha

Na demonstração controlada de falha, a qualidade identificou correspondência de join de 83,4%, abaixo do limite mínimo de 95%, além de oito chaves duplicadas. As duas condições foram classificadas como bloqueantes no cenário de teste e o gate impediu a publicação. A demonstração comprova que a camada de qualidade interrompe o fluxo quando os critérios de aprovação não são atendidos; ela não representa falha na Gold oficial.

A validação cruzada entre a taxa recalculada a partir dos microdados ponderados e a taxa oficial do INEP apresentou concordância em 12.351 de 12.408 recortes (99,5%), considerando tolerância de 1 ponto percentual. Os 57 recortes restantes divergiram além dessa tolerância. Em um caso investigado, os microdados indicaram 55,6%, enquanto a taxa publicada foi 91,67%; a diferença foi localizada entre tabelas da fonte e sua causa não foi identificada.

5. Dashboards e valor para análises educacionais

O dashboard “Análise de Indicadores de Alfabetização — INEP” possui três perspectivas: visão geral nacional, análise por município e análise por rede de ensino.

Visão	Análises apoiadas
Nacional	Indicadores gerais, municípios avaliados, atingimento de metas e distribuição por UF e situação da meta.
Por município	Maiores e menores taxas, distribuição por faixas e comparação entre taxa observada e meta disponível.
Por rede de ensino	Comparação dos indicadores e da situação das metas por tipo de rede.

Na captura do painel nacional, os indicadores legíveis e utilizados neste relatório são a taxa média de alfabetização (61,5) e o total de municípios avaliados (5,5 mil). Os cartões “Municípios que atingiram a meta” (2,79 mil) e “% que atingiram a meta” (25,6) foram omitidos da síntese numérica porque, na captura, a relação entre eles e o total de municípios não fica clara.

As capturas também mostram gráficos de distribuição por faixa municipal, comparação taxa versus meta e situação da meta por rede. Como os valores exatos de todas as barras não estavam legíveis nas imagens, este relatório não atribui números estimados a essas categorias.

6. Monitoramento, alertas e orquestração

A solução possui cinco alertas SQL com avaliação horária. Na captura realizada, três estavam em estado OK e dois estavam acionados (Triggered): taxa de correspondência de joins e chave duplicada. Triggered indica que a condição definida na consulta do alerta foi satisfeita no período avaliado; não significa, por si só, que a execução do Job falhou. A leitura deve ser feita em conjunto com o resultado do Job de qualidade: na execução Gold mostrada, houve zero bloqueios e o gate foi liberado.

Alerta	Estado na captura
Status de execução do pipeline	OK
Variação anormal de volume	OK
Taxa de correspondência de joins	Triggered
Chave duplicada	Triggered
Chave nula	OK

A captura da AWS Step Functions mostra a execução sequencial dos sete Jobs Databricks, todos concluídos com sucesso.

Na execução de 26/10/2026, o pipeline registrou 41 etapas e concluiu o fluxo em 21 minutos e 02 segundos, sem falhas nessa execução. As métricas de execução e de qualidade são persistidas para permitir acompanhamento histórico.

7. Processamento contínuo (simulado)

Além do processamento em lotes, foi executada uma simulação de processamento contínuo de eventos, com ciclos de produtor, espera simulada e consumidor incremental por micro-lotes. Os eventos são marcados com origem SIMULADO; portanto, os resultados não representam integração de produção com um sistema externo de mensageria.

Indicador da execução	Resultado
Eventos recebidos na Bronze	130
Reentregas identificadas	30
Eventos únicos registrados na Silver	94
Eventos inválidos	8
Latência média observada	12,63 segundos
Latência mínima / máxima	7,55 / 31,55 segundos

Os oito eventos inválidos foram classificados por motivo: código de rede desconhecido (1), taxa de alfabetização nula (3), taxa negativa (3) e taxa superior a 100 (1). A latência média observada foi de aproximadamente 12,6 segundos, dentro da simulação; não deve ser apresentada como latência de um serviço de streaming em produção.

8. Custos (FinOps)

A projeção mensal mais recente totaliza US$ 38,33, considerando as quantidades medidas e os preços preenchidos para Databricks Serverless, BigQuery on-demand e AWS Step Functions Standard. O cálculo considera 30 execuções mensais e os parâmetros apresentados no notebook de FinOps.

Serviço	Quantidade exibida	Preço unitário	Custo mensal calculado
Databricks Serverless (Jobs)	109,08 DBU-h (3,636 por execução × 30)	US$ 0,35 por DBU-h	US$ 38,18
BigQuery (ingestão on-demand)	0,254 GiB por carga × 30 = 7,62 GiB (0,0074 TiB)	US$ 6,25 por TiB	US$ 0,05
AWS Step Functions (Standard)	4,26 mil transições (142 por execução × 30)	US$ 0,025 por mil transições	US$ 0,11

O total de US$ 38,33 é uma projeção mensal baseada em 30 execuções. Para o BigQuery, o volume considerado é de 0,254 GiB por carga, equivalente a aproximadamente 7,62 GiB no mês, dentro da franquia mensal gratuita de 1 TiB indicada no modelo. O custo calculado na tabela é residual pela tarifa unitária informada; a aplicação da franquia gratuita pode tornar a cobrança efetiva de BigQuery igual a zero. Para AWS, foram consideradas 142 transições por execução, ou 4.260 transições no mês. Os preços unitários foram preenchidos no notebook a partir das fontes de preço registradas.

9. Inteligência artificial

A camada Gold foi estruturada para apoiar a preparação de um conjunto de variáveis por município, série e rede. Para uma futura modelagem, o alvo será o atingimento da meta no ano T, enquanto as variáveis explicativas serão limitadas ao ano T-1 ou anteriores, evitando vazamento de informação do próprio período-alvo. Com essa separação temporal, modelos poderão ser estudados para identificar padrões, estimar tendências e sinalizar municípios que merecem atenção adicional. Essas aplicações são possibilidades futuras, não resultados de modelos preditivos já avaliados nesta etapa.

Antes de utilizar previsões para orientar políticas públicas, será necessário validar a qualidade e a cobertura temporal dos dados, definir variáveis de entrada, evitar vazamento de informação entre períodos e avaliar desempenho e possíveis vieses.

10. Limitações e próximos passos

- O streaming apresentado é simulado e utiliza eventos identificados como SIMULADO.
- As ocorrências informativas de correspondência e de ausência de metas permanecem registradas e devem ser interpretadas conforme o escopo e o período das tabelas.
- A projeção de custos não inclui a transferência de dados entre a Google e a AWS nem o armazenamento, que não foram medidos.
- Os estados dos alertas refletem o momento da captura e podem mudar em execuções posteriores.
- A aplicação de inteligência artificial é apresentada como evolução possível. O conjunto de dados preparado para a Fase 3 deve utilizar como variáveis explicativas apenas informações do ano T-1 ou anteriores para prever o atingimento da meta no ano T, evitando vazamento do alvo.
- A validação cruzada dos microdados com a taxa oficial apresentou 99,5% de concordância (12.351 de 12.408 recortes), com 57 divergências acima de 1 ponto percentual; a causa de todas as divergências ainda não foi estabelecida.
- A projeção de custos é mensal e considera 30 execuções; os valores podem variar conforme consumo real, preços vigentes, região e aplicação de franquias gratuitas.

11. Conclusão

O projeto entrega uma estrutura integrada para ingestão, tratamento, validação, monitoramento e análise de dados de alfabetização. As evidências compartilhadas demonstram a execução bem-sucedida da orquestração dos sete Jobs, a aplicação de regras de qualidade em diferentes camadas, a geração de tabelas analíticas e a disponibilização de dashboards com visões nacional, municipal e por rede.

A solução cria uma base para análises educacionais mais consistentes e para futuras iniciativas de inteligência artificial, mantendo explícitas as limitações e os pontos que ainda precisam de evolução.